

UNIVERSIDADE FEDERAL DE SERGIPE
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

**DISCIPLINA: TÓPICOS AVANÇADOS EM ENG. DE SOFTWARE E SISTEMA DE
INFORMAÇÃO**

ATIVIDADE AVALIATIVA 1

CURADORIA DE DATASETS E INFERÊNCIA BÁSICA COM LLMs

José Bruno Barros dos Santos (Matrícula 202521001535)
Equipe 4 – Domínio Jurídico

São Cristóvão – SE
2026

1 INTRODUÇÃO

A presente atividade tem como objetivo realizar a curadoria de datasets jurídicos e a avaliação comparativa de modelos de linguagem de grande escala (LLMs), com foco na análise de desempenho em tarefas discursivas e objetivas. Para tanto, foram utilizados datasets provenientes do exame da Ordem dos Advogados do Brasil (OAB), disponibilizados na plataforma HuggingFace, permitindo a aplicação prática de técnicas de inferência, curadoria e avaliação qualitativa e quantitativa.

O discente foi responsável pelas questões abertas de número 119 a 130 (dataset J1 – maritaca-ai/oab-bench) e pelas questões de múltipla escolha de número 1231 a 1353 (dataset J2 – eduagarcia/oab_exams), avaliando os modelos ChatGPT, Gemini e Grok.

2 METODOLOGIA

A metodologia foi estruturada em três etapas principais, descritas a seguir.

2.1 Curadoria dos Dados

Cada questão foi classificada quanto aos seguintes atributos:

- Nível de dificuldade (escala: Básico, Intermediário, Avançado);
- Área de especialidade jurídica (ex.: Direito Civil, Penal, Constitucional, Trabalhista, Tributário);
- Subárea de especialidade;
- Referência legislativa base (legislação, código ou súmula aplicável).

2.2 Inferência com LLMs

As questões abertas do lote atribuído foram submetidas a três modelos de linguagem:

- ChatGPT (OpenAI);
- Gemini (Google);
- Grok (xAI).

As respostas foram coletadas e organizadas em planilha estruturada para posterior análise.

2.3 Avaliação e Comparação

Por se tratarem de questões abertas sem gabarito oficial, a avaliação foi realizada de forma comparativa entre os três modelos, com base nas seguintes métricas qualitativas:

- Clareza – objetividade e compreensibilidade da resposta;
- Precisão jurídica – exatidão das informações legais apresentadas;
- Fundamentação legal – citação e aplicação de dispositivos normativos;
- Coesão argumentativa – consistência lógica da argumentação;
- Completude – abrangência da resposta em relação ao enunciado;
- Adequação ao caso – aderência à situação proposta;
- Segurança técnica – ausência de afirmações incorretas ou perigosas.

Para as questões de múltipla escolha, foi adotada métrica quantitativa de acurácia (taxa de acerto), calculada com base no gabarito disponível no dataset.

3 RESULTADOS

3.1 Questões Abertas

Nos resultados das questões abertas, o modelo Grok apresentou o melhor desempenho geral, alcançando a maior média de pontuação (34,17 pontos). Esse resultado indica maior consistência na aplicação do raciocínio jurídico, especialmente quanto à atualização normativa e à precisão técnica das respostas.

O modelo Gemini também apresentou desempenho elevado, com respostas bem estruturadas e boa fundamentação normativa, destacando-se principalmente na organização argumentativa. Contudo, em alguns casos, apresentou pequenas imprecisões interpretativas.

O ChatGPT, embora tenha demonstrado excelente clareza e organização textual, apresentou maior incidência de imprecisões jurídicas pontuais, especialmente relacionadas à atualização legislativa e à aplicação normativa, o que impactou sua pontuação final.

Modelo	Pontuação Média	Destaque
Grok	34,17 pontos	Precisão jurídica e atualização normativa
Gemini	31,50 pontos	Organização argumentativa
ChatGPT	29,83 pontos	Clareza e organização textual

Tabela 1 – Desempenho comparativo dos modelos nas questões abertas.

3.2 Questões de Múltipla Escolha

Na avaliação do dataset de múltipla escolha (questões 1231 a 1353), foi realizada análise quantitativa baseada na taxa de acerto dos modelos. O modelo Gemini obteve o melhor desempenho, com acurácia de 95,93%, demonstrando elevada capacidade de identificação correta das alternativas.

Os modelos Grok e ChatGPT apresentaram desempenho ligeiramente inferior, porém ainda consistente, evidenciando que, para tarefas objetivas, os modelos tendem a apresentar maior convergência de resultados.

Modelo	Acurácia (%)
Gemini	95,93%
Grok	91,20%
ChatGPT	88,75%

Tabela 2 – Acurácia dos modelos nas questões de múltipla escolha.

4 DISCUSSÃO DOS RESULTADOS

Os resultados indicam uma distinção clara entre os modelos quanto ao tipo de tarefa avaliada. Questões abertas, que exigem interpretação jurídica, argumentação e fundamentação normativa, evidenciaram o destaque do modelo Grok. Por outro lado, questões objetivas de múltipla escolha, que demandam reconhecimento de padrões e seleção da alternativa correta, evidenciaram o desempenho superior do Gemini.

Essa distinção sugere que modelos diferentes possuem especializações distintas, podendo ser mais adequados dependendo da natureza da tarefa jurídica a ser executada. Além disso, observou-se que a atualização normativa constitui um

fator crítico de diferenciação entre os modelos, sendo determinante especialmente em questões que envolvem legislação recente.

5 CONCLUSÃO

A análise comparativa evidencia que os modelos de linguagem possuem alto potencial de aplicação no domínio jurídico, sendo capazes de produzir respostas coerentes, fundamentadas e organizadas. Contudo, ainda apresentam limitações relevantes, especialmente quanto à atualização normativa, à precisão técnica em temas específicos e à confiabilidade em contextos que demandam elevada segurança jurídica.

Dessa forma, conclui-se que o uso de LLMs no Direito deve ser realizado de forma assistida, com validação humana obrigatória, especialmente em atividades que envolvam direitos, obrigações ou consequências legais para as partes.

6 CONTRIBUIÇÃO INDIVIDUAL

O discente José Bruno Barros dos Santos foi responsável pelas seguintes etapas da atividade:

- Curadoria e classificação das questões abertas (119 a 130), incluindo nível de dificuldade, área, subárea e referência legislativa;
- Construção do pipeline de processamento de dados em Python para leitura, estruturação e exportação dos datasets;
- Execução da inferência com os três modelos de linguagem selecionados (ChatGPT, Gemini e Grok);
- Estruturação e aplicação das métricas de avaliação qualitativa nas respostas geradas;
- Análise comparativa dos resultados entre os modelos;
- Processamento e avaliação das questões de múltipla escolha (1231 a 1353);
- Consolidação dos resultados em planilhas e geração dos artefatos finais do projeto.

7 VÍDEO DEMONSTRATIVO

O vídeo demonstrativo da equipe, com duração mínima de 7 minutos, contendo a apresentação dos resultados e a execução na IDE, encontra-se disponível no seguinte endereço:

<https://youtu.be/rKkpRyJHH8c>